Современный статический анализ кода: что умеет он, чего не умели линтеры

Павел Беликов
PVS-Studio

Содержание

- чем должен и не должен заниматься статический анализ
- методики анализа: от первых утилит до современных анализаторов
  - поиск по подстроке/регулярным выражениям
  - pattern-based analysis
  - symbolic execution
  - межпроцедурный анализ
- современная инфраструктура анализаторов

Немного о нас

- PVS-Studio - статический анализатор C, C++, C# кода
- Поддерживаются Windows и Linux (C, C++)
- Плагин для Visual Studio
- Средства для быстрой проверки (Standalone, pvs-studio-analyzer)

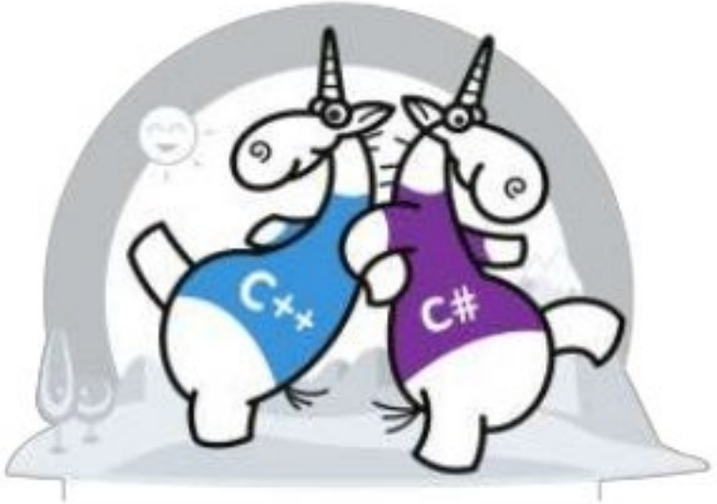

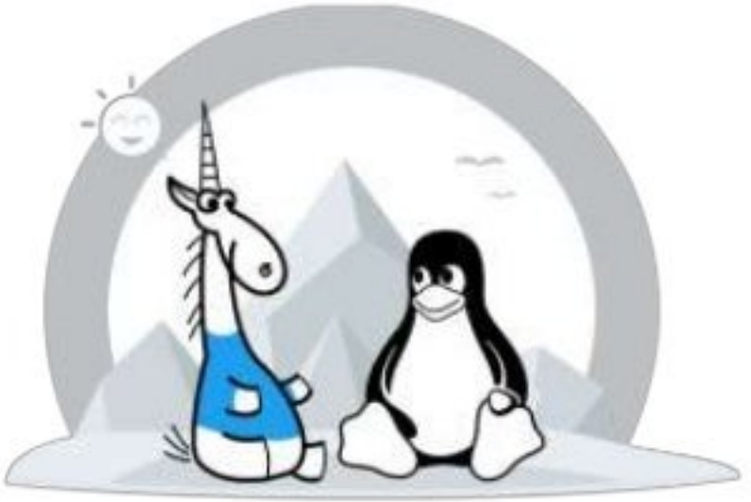

Цели статического анализа

- поиск ошибок в логике программы
- поиск уязвимостей
- упрощение процесса разработки
- экономия

Чем **не должен** заниматься статический анализ

- поиск “стилистических” ошибок
- соответствие каким-либо guideline
- предложениями переписать код на новый стандарт

Почему?

- для всего это есть отдельные инструменты
- в большом проекте таких срабатываний будут тысячи

Как определить качество статического анализа

Существуют два типа ошибок, которым подвержены анализаторы:

- ошибки первого рода - false positives
- ошибки второго рода - false negatives

Ценность анализа в минимальном количестве ошибок первого рода.

Никто не будет пользоваться анализатором, который выдаёт 1000 ложных срабатываний на одну ошибку.

С чего всё начиналось

- использование небезопасных функций
- возможные опечатки
- типовые ошибки, связанные с недостаточным знанием языка
- несоответствие принятому стилю кодирования

- такие ошибки ищутся и сейчас, отличаются методики поиска
- многие из них уже есть в компиляторах
- поиск по подстроке, регулярным выражениям или лексем ведёт к излишнему количеству ложных срабатываний

Пример опечатки

Ошибка из проекта **Linux**

```
char *stime[] = { "400ms", "5min", "10min", "15min",
      "20min", "25min", "30min" "No timeout" };
```

Предупреждение PVS-Studio: V653 A suspicious string consisting of two parts is used for array initialization. It is possible that a comma is missing. Consider inspecting this literal: «30min» «No timeout». lp8788-charger.c 657

Поиск по регулярным выражениям

Некоторые их используют до сих пор. Пример из CppCheck:

```
<?xml version="1.0"?>
<rule version="1">
    <pattern> if \( ([!] )*?(strlen) \( \w+? \) ([>] [0] )*?\) { </pattern>
    <message>
        <id>StrlenEmptyString</id>
        <severity>performance</severity>
        <summary>Using strlen() to check if a string is empty is not
efficient.</summary>
    </message>
</rule>
```

Но у такого подхода серьёзные проблемы с масштабируемостью.

С чем же работает современный статический анализ

- представление кода в виде AST (или байткода, но это отдельный разговор)
- AST должно быть типизированным
- полная семантическая модель программы

Pattern-based analysis

- *относительно* прост в реализации
- позволяет находить опечатки и последствия Copy-Paste
- в основе метода - поиск какого-то паттерна в AST
- для исключений может использоваться информация о типах и значениях

Пример поиска паттерна

Ошибка из проекта **Oracle VM Virtual Box**

```
static const uint8_t g_acDaysInMonths[12];
static const uint8_t g_acDaysInMonthsLeap[12];

static PRTTIME rtTimeNormalizeInternal(PRTTIME pTime)
{
  ....
  unsigned cDaysInMonth = fLeapYear
    ? g_acDaysInMonthsLeap[pTime->u8Month - 1]
    : g_acDaysInMonthsLeap[pTime->u8Month - 1];
  ....
}
```

Предупреждение PVS-Studio: V583 The '?:' operator, regardless of its conditional expression, always returns one and the same value: g_acDaysInMonthsLeap[pTime->u8Month - 1]. time.cpp 453

Пример паттерна с исключением

Ошибка из проекта **Serious Engine 1 v.1.10**

```
void CWorldEditorApp::OnConvertWorlds() {
  ....
  char achrLine[256];
  ....
  fsFileList.Open_t( fnFileList);
  while( !fsFileList.AtEOF()) {
    fsFileList.GetLine_t( achrLine, 256);
    // increase counter only for lines that are not blank
    if( achrLine != "") ctLines++;
  }
  fsFileList.Close();
  ....
}
```

Предупреждение PVS-Studio: V547 Expression 'achrLine != ""' is always true. To compare strings you should use strcmp() function. worldeditor.cpp 2254

Пример паттерна с исключением

```
#define MY_STREQ(a,b) ((a) == (b) || strcmp(a, b) == 0)
```

Паттерн с типами

Ошибка из проекта **Wolfenstein 3D**

```
void BG_ParseConditionBits(
  char **text_pp, animStringItem_t *stringTable,
  int condIndex, int result[2] )
{
  ...
  memset( result, 0, sizeof( result ) );
  ...
}
```

Предупреждение PVS-Studio: V511 The sizeof() operator returns size of the pointer, and not of the array, in 'sizeof (result)' expression. cgame bg_animation.c 807

Иногда и этого мало

Ошибка из проекта **Linux**

```
#define CFS_FAIL_TIMEOUT(id, secs) \
cfs_fail_timeout_set(id, 0, secs * 1000, CFS_FAIL_LOC_NOSET)

#define OBD_FAIL_TIMEOUT(id, secs) \
CFS_FAIL_TIMEOUT(id, secs)

int ptl_send_rpc(struct ptlrpc_request *request, int noreply)
{
  ....
  OBD_FAIL_TIMEOUT(OBD_FAIL_PTLRPC_DELAY_SEND,
                   request->rq_timeout + 5);
  ....
}
```

Предупреждение PVS-Studio: V733 It is possible that macro expansion resulted in incorrect evaluation order. Check expression: request->rq_timeout + 5 * 1000. niobuf.c 637

Symbolic execution

- самая сложная и самая полезная часть анализатора
- опирается на control flow analysis, data flow analysis
- позволяет осуществлять bounds checking, pointer analysis
- вычисление диапазонов переменной позволяет сэкономить на времени анализа

Разыменование нулевого указателя

Ошибка из проекта **D programming language**

```
Expression *getVarExp(Loc loc, InterState *istate, Declaration *d, CtfeGoal
goal) {
  ....
  VarDeclaration *v = d->isVarDeclaration();
  if (v) {
    ....
  } else if (s) {
    if (s->dsym->toInitializer() == s->sym)
      ....
    else
      error(loc, "cannot interpret symbol %s at compile time",
            v->toChars());
  }
  ....
}
```

Предупреждение PVS-Studio: V522 Dereferencing of the null pointer 'v' might take place. interpret.c 1711

Разыменование нулевого указателя

- можно попытаться искать такие ошибки в AST, но не стоит
- вычислив значение указателя, мы можем находить более сложные ошибки

Пример:

```
void report_error() {
  throw std::runtime_error("error");
}

int* new_int() {
  ....
  int* p = some_condition ? new int : nullptr;
  if (p == nullptr) // <= условие
    report_error(); // <= не возвращает управления
  *p = 0;           // <= p != nullptr, всё хорошо
  return p;
}
```

Разыменование нулевого указателя

Ошибка из проекта **Clang**

```
Expected<std::unique_ptr<PDBFile>>
PDBFileBuilder::build(
  std::unique_ptr<msf::WritableStream> PdbFileBuffer)
{
  ....
  auto File = llvm::make_unique<PDBFile>(
    std::move(PdbFileBuffer), Allocator);

  File->ContainerLayout = *ExpectedLayout;

  if (Info) {
    auto ExpectedInfo = Info->build(*File, *PdbFileBuffer);
  ....
}
```

Предупреждение PVS-Studio: V522 Dereferencing of the null pointer 'PdbFileBuffer' might take place. PDBFileBuilder.cpp 106

Разыменование нулевого указателя

Ошибка из проекта **Unreal Engine 4**

```
void UGameplayStatics::DeactivateReverbEffect(....)
{
  if (GEngine || !GEngine->UseSound())
  {
    return;
  }
  UWorld* ThisWorld = GEngine->GetWorldFromContextObject(....);
  ....
}
```

Предупреждение PVS-Studio: V522 Dereferencing of the null pointer 'GEngine' might take place. Check the logical condition. gameplaystatics.cpp 988

Control flow analysis

Какие конструкции не вернут управление:

- return
- исключение
- стандартная функция
- [[noreturn]]
- __attribute__((noreturn))
- __declspec(noreturn)
- создание временного объекта, деструктор которого бросает исключение
- вызов пользовательской функции, не возвращающей управление
- goto
- break, continue

Всё это нужно учитывать при вычислении возможных значений переменной

Анализ функции

Ошибка из проекта **Chromium**

```
static int BlockSizeForFileType(FileType file_type) {
    switch (file_type) {
      ....
      default:
        return 0;
    }
}

static int RequiredBlocks(int size, FileType file_type) {
  int block_size = BlockSizeForFileType(file_type);
  return (size + block_size - 1) / block_size;
}
```

Предупреждение PVS-Studio: V609 Divide by zero. Denominator range [0..4096]. addr.h 159

Bounds checking

Пример из мира 64-битных ошибок:

```
unsigned short f();
int g();

void test(void *p, void *p2) {
  int x = f();
  memset(p, 0, x);  // <= всё нормально, x = [0; 65535]
  int y = g();
  memset(p2, 0, y); // <= подозрительно, int -> memsize
}
```

Lifetime safety

Ошибка из проекта **Clang**

```
SingleLinkedListIterator<T> &operator++(int) {
  SingleLinkedListIterator res = *this;
  ++*this;
  return res;
}
```

Предупреждение PVS-Studio: V558 Function returns the reference to temporary local object: res. LiveInterval.h 679

Путаница в new/malloc

Ошибка из проекта **Mozilla Thunderbird**

```
NPError NPP_New(....)
{
  ....
  InstanceData* instanceData = new InstanceData;
  ....
  free(instanceData);
  ....
}
```

Предупреждение PVS-Studio: V611 The memory was allocated using 'new' operator but was released using the 'free' function. Consider inspecting operation logics behind the 'instanceData' variable. nptest.cpp 971

Простой пример

```
void foo()
{
  int x = 1;
  ....
  if (x == 1) // <= всегда true, ошибка или нет?
    return;
}
```

- часто такой код используют для compile-time отключения функционала
- пример хорошо иллюстрирует неэффективность маленьких искусственных тестов

Межпроцедурный анализ

Рекурсивный анализ

- очень точный
- очень медленный

Аннотирование

- можно составлять аннотации, анализируя тело функции
- для популярных библиотек составляются ручные аннотации
- отлично масштабируется

Проблемы межпроцедурного анализа

- виртуальные методы
- указатели на функции
- межмодульный анализ
- динамическая линковка

Анализ функции

- возможные значения
- область значений для параметров функции
- модификация аргументов, переданных по ссылке или указателю
- анализ на noreturn
- отсутствие побочных эффектов

Аннотации: нет состояния

Ошибка из проекта **Clang**

```
std::pair<Function *, Function *>
llvm::createSanitizerCtorAndInitFunctions(
    ....
    ArrayRef<Type *> InitArgTypes, ArrayRef<Value *> InitArgs,
    ....)
{
  assert(!InitName.empty() && "Expected init function name");
  assert(InitArgTypes.size() == InitArgTypes.size() &&
    "Sanitizer's init function expects "
    "different number of arguments");
  ....
}
```

Предупреждение PVS-Studio: V501 There are identical sub-expressions 'InitArgTypes.size()' to the left and to the right of the '==' operator. ModuleUtils.cpp 107

Аннотации: строка в определённом регистре

Ошибка из проекта **CodeLite**

```
struct NodeJSHandle {
  wxString type;
  ....
  bool IsString() const {return type.Lower() == "string";}
  bool IsArray() const {return type.Lower() == "Array"; }
};
```

Предупреждение PVS-Studio: V547 Expression 'type.Lower() == "Array"' is always false. NodeJSOuptutParser.h 61

Аннотации: значение должно быть использовано

Ошибка из проекта **Qt**

```
int main(int argc, char **argv)
{
  ....
  QByteArray arg(argv[a]);
  ....
  arg = arg.mid(1);
  arg.toLower();
  if (arg == "o")
  ....
}
```

Предупреждение PVS-Studio: V530 The return value of function 'toLower' is required to be utilized. main.cpp 72

Аннотации: restrict аргументы

Ошибка из проекта **Chromium**

```
void DiskCacheEntryTest::ExternalSyncIOBackground(....) {
  ....
  scoped_refptr<net::IOBuffer>
    buffer1(new net::IOBuffer(kSize1));
  scoped_refptr<net::IOBuffer>
    buffer2(new net::IOBuffer(kSize2));
  ....
  EXPECT_EQ(0, memcmp(buffer2->data(), buffer2->data(), 10000));
  ....
}
```

Предупреждение PVS-Studio: V549 The first argument of 'memcmp' function is equal to the second argument. entry_unittest.cc 393

Аннотации: аргумент функции - количество байт

Ошибка из проекта **Miranda IM**

```
static BOOL ImageArray_Alloc(LP_IMAGE_ARRAY_DATA iad, int size)
{
  ...
  memset(&iad->nodes[iad->nodes_allocated_size],
         (size_grow - iad->nodes_allocated_size) *
sizeof(IMAGE_ARRAY_DATA_NODE),
         0);
  ...
}
```

Предупреждение PVS-Studio: V575 The 'memcmp' function processes '0' elements. Inspect the 'third' argument. clist_modern modern_image_array.cpp 59

Пользовательские аннотации

- требуют большой работы по аннотированию всей кодовой базы
- индивидуальны для инструмента
- затрудняет чтение кода
- анализатор должен работать сразу

Тестирование

- есть только один верный способ тестирования - реальные проекты
- это помогает понять, какие правила дают много ложных срабатываний
- нельзя ругаться на код, если это общепринятая практика
- даже если вы с ней не согласны

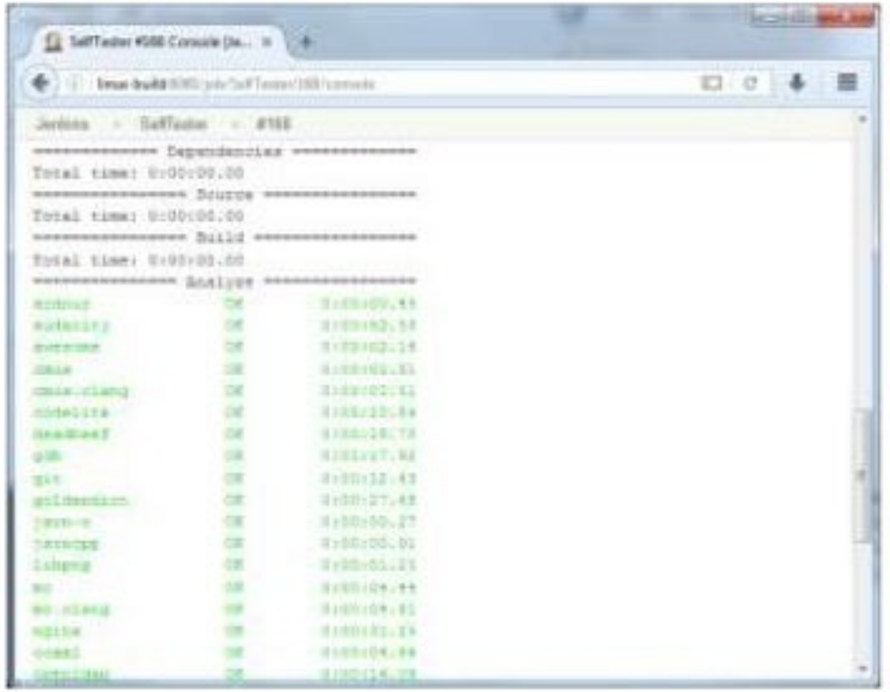

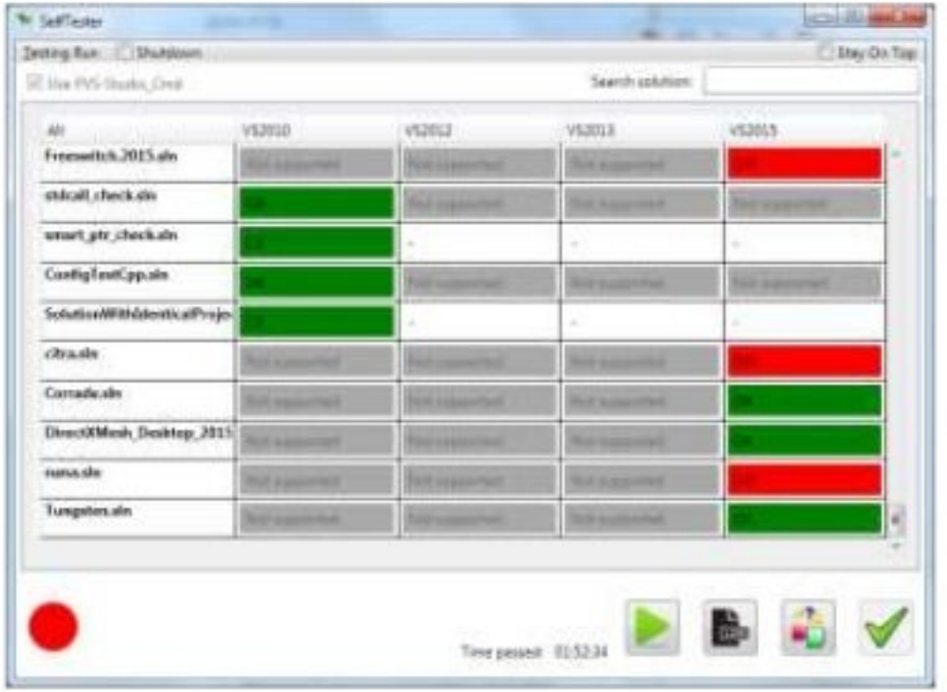

Написание своих правил для анализатора

- хорошо для линтеров, проверяющих простые паттерны ошибок
- но плохо для статических анализаторов
- написать API, позволяющий работать со всеми видами анализа - огромная работа
- сделать его стабильным ещё сложнее
- пользователи не захотят писать полноценные правила для анализатора

Ранжирование результатов анализа

- не все ошибки одинаково опасны
- некоторые диагностики могут тяготеть к ложным срабатываниям
- логично разделить ошибки на уровни
- отдельные категории диагностик: 64-битные, микрооптимизации

Как осуществить такой анализ?

- анализ исходных файлов уже не работает
- отталкиваться приходится от конкретных компиляторов
- сборочные системы

Как осуществить такой анализ?

- такое многообразие окружений накладывает свои требования
- необходимо уметь проверять проект, независимо от системы сборки
- необходимо парсить код для любого компилятора
- необходимо всё это тестировать (ура, больше исключений)

Интеграция в процесс разработки

- статический анализатор - инструмент для разработчика
- инкрементальный анализ
- приемлемая скорость анализа
- подавление ложных срабатываний - assert, комментарии, база разметки

Интеграция в QA

- запуск на сборочных серверах
- рассылка html-отчёта по почте
- интеграция в Code Quality платформы (например, SonarQube)

Q&A

Почта: support@viva64.com

Блог на хабре: https://habrahabr.ru/company/pvs-studio/

Скачать PVS-Studio: http://www.viva64.com/ru/pvs-studio/

Для открытых некоммерческих проектов есть бесплатная лицензия